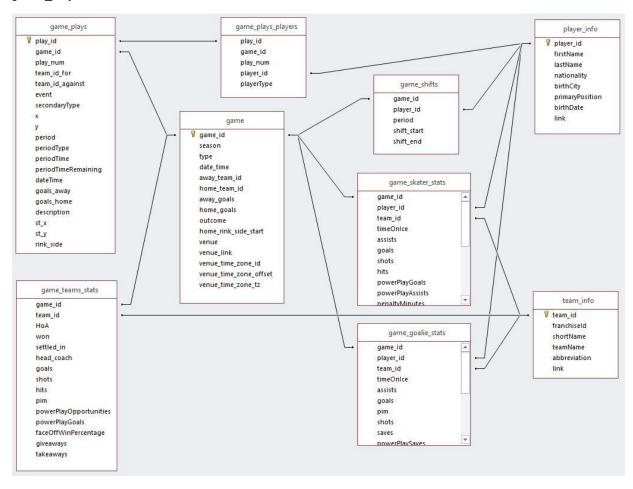
Semestrální práce – NHL data

Neo4j, MongoDB

NI-PDB 2022/2023, Tomáš Kalabis

Popis dat

Vybral jsem si jako téma práce data z hokejové ligy NHL. Data jsou dostupné na *Kaggle* pod <u>tímto odkazem</u>. Popisují základní údaje o hráčích, jednotlivé zápasy a statistiky tohoto zápasu, statistiky jednotlivých hráčů v jednotlivých zápasech. Data dále popisují údaje rozhodčích, údaje o jednotlivých událostech v zápase podrobněji. Ty jsem však nezahrnoval, kvůli přílišné komplikovanosti databáze. Dále jsem zahrnul data zápasů pouze ze sezóny 2019/2020 kvůli velikosti dat a dlouhému výpočetnímu času create skriptu (po zmenšení ° 1,312 zápasů). Vyjmul jsem také některé nezajímavé atributy tabulek jako časová pásma míst konání zápasů. Původní konceptuální model vypadá zhruba následovně. V upravené verzi nepočítám s tabulkami *game_plays, game_plays_players* a *game_shifts*.



MongoDB

Nejdříve bylo nutné vytvořit create script, který byl vytvořen v Pythonu. Jednotlivé datové kolekce jsou uložené v JSON formátu - konkrétně kolekce *game* a *player*. Kolekce player je přepsaná tabulka, *player_info*. Kolekce *game* je tabulka *game* s přidanými údaji z *team_info*, *game_team_stats* a statistiky jednotlivých hráčů v zápase (tabulky *game_skater_stats*, *game_goalie_stats*). Ukázky vkládaných dat viz níže.

Kolekce Game

```
{"game id":2019020001, "season":20192020, "type": "R", "date time GMT":"
2019-10-
02T23:00:00Z", "home team": "Canucks", "away team": "Predators", "outcome
":"home win
REG", "away goals":3, "home goals":5, "home players": "{8477939:
{'timeOnIce': 1025.0, 'assists': 1.0, 'goals': 0.0, 'shots': 3.0,
'hits': 0.0, 'powerPlayGoals': 0.0, 'powerPlayAssists': 0.0,
'penaltyMinutes': 0.0, 'faceOffWins': 0.0, 'faceoffTaken': 4.0,
'takeaways': 1.0, 'giveaways': 1.0, 'shortHandedGoals': 0.0,
'shortHandedAssists': 0.0, 'blocked': 0.0, 'plusMinus': 0.0,
'evenTimeOnIce': 804.0, 'shortHandedTimeOnIce': 0.0,
'powerPlayTimeOnIce': 221.0},
8475883: {'timeOnIce': 3591, 'assists': 0, 'goals': 0, 'pim': 0,
'shots': 26, 'saves': 23, 'powerPlaySaves': 0, 'shortHandedSaves':
2, 'evenSaves': 21, 'shortHandedShotsAgainst': 2,
'evenShotsAgainst': 24, 'powerPlayShotsAgainst': 0, 'decision': 'W',
'savePercentage': 88.4615384615385, 'powerPlaySavePercentage': nan,
'evenStrengthSavePercentage':
87.5}}", "away players": "{...}", "team stats": "{'home': {'head coach':
'Mike Babcock', 'shots': 42.0, 'pim': 6.0, 'hits': 17.0}, 'away':
{'head coach': 'D.J. Smith', 'shots': 26.0, 'pim': 10.0, 'hits':
44.0}"}
```

```
db.game.insertOne({
```

Kolekce Player

```
{"player_id":8466148,"firstName":"Marian","lastName":"Hossa","nation
ality":"SVK","birthCity":"Star\u00e1
Lubovna","primaryPosition":"RW","birthDate":"1979-01-12
00:00:00","birthStateProvince":null,"height":"6'
1\"","height cm":185.42,"weight":207.0,"shootsCatches":"L"}
```

Neo4i

Nejdříve byly vytvořeny 3 typy vrcholů - GAME, PLAYER, GAME_STATS. Vrcholy GAME popisují zápas a výsledky bez statistik hráčů a statistik týmů. Dále vrcholy PLAYER popisuje informace o hráčích (stejně jako v případě MongoDB) a konečně GAME_STATS, které popisují statistiky týmů během hry. Dále jsou přídány 2 druhy vztahů mezi vrcholy – PLAYS, HAS_STATS. Vztah PLAYS je mezi hráčem který hraje v zápase. Každý tento vztah má atributy zachycující statistiky daného hráče v daném zápase. Druhý vztah spojuje zápas s statistikami daného zápasu.

Vrchol GAME

```
CREATE (g0: GAME {game_id: 2019020001, season: 20192020, type: 'R', date_time_GMT: '2019-10-02T23:00:00Z', home_team: 'Maple Leafs', away_team: 'Senators', outcome: 'home win REG', away_goals: 3, home goals: 5} ), ...
```

Vrchol PLAYER

```
CREATE (p0: PLAYER {player_id: 8466148, firstName: 'Marian', lastName: 'Hossa', nationality: 'SVK', birthCity: 'Stará Lubovna', primaryPosition: 'RW', birthDate: '1979-01-12 00:00:00', birthStateProvince: nan, height: '6\' 1"', height_cm: 185.42, weight: 207.0, shootsCatches: 'L'}), ...
```

Vrchol GAME STATS

```
CREATE (gs0h: GAME_STATS {head_coach: 'Mike Babcock', shots: 42.0, pim: 6.0, hits: 17.0} ), ...
```

Vztah HAS STATS

```
CREATE (g0)-[hs0h: HAS STATS {team: 'Maple Leafs'}]->(gs0h), ...
```

Vztah PLAYS

```
CREATE (p460) - [p1629a0: PLAYS {player_id: 8476923.0, timeOnIce: 1443.0, assists: 0.0, goals: 0.0, shots: 2.0, hits: 2.0, powerPlayGoals: 0.0, powerPlayAssists: 0.0, penaltyMinutes: 2.0, faceOffWins: 0.0, faceOffTaken: 0.0, takeaways: 1.0, giveaways: 1.0, shortHandedGoals: 0.0, shortHandedAssists: 0.0, blocked: 2.0, plusMinus: 0.0, evenTimeOnIce: 1224.0, shortHandedTimeOnIce: 61.0, powerPlayTimeOnIce: 158.0, team: 'Devils'}]->( g629 ), ...
```

Poznámka:

Jednotlivé vrcholy a vztahy byli nahrány do databáze přes webový prohlížeč kromě vztahu PLAYS. Vztah PLAYS kvůli své velikosti byl načten ze souboru csv. Jednotlivé příkazy a csv soubor byly vytvořeny v přiložením jupyter notebooku.

Dotazy

Dotaz 1

Získejte všechny zápasy v základní části 2019/2020 týmu "Bruins"

```
MongoDB
```

Neo4j

```
match (g:GAME)
where g.season = 20192020 and
(g.home_team = "Bruins" or g.away_team = "Bruins")
and g.type = "R"
return g
```

```
{"home_goals":1, "season":20192020, "home_team":"Stars", "away_goals":2, "type":"R", "date_time_GMT":"2019-10-04T00:30:002", "outcome":"away win REG", "game_id":2019 1002010, "away_team":"Bruins"}

{"home_goals":6, "season":20192020, "home_team":"Coyotes", "away_goals":1, "type":"R", "date_time_GMT":"2019-10-06T01:00:002", "outcome":"away win REG", "game_id":2019020027, "away_team":"Bruins"}

{"home_goals":3, "season":20192020, "home_team":"Golden Knights", "away_goals":4, "type":"R", "date_time_GMT":"2019-10-09T02:00:002", "outcome":"away win REG", "game_id":2019020043, "away_team":"Bruins"}

{"home_goals":4, "season":20192020, "home_team":"Avalanche", "away_goals":2, "type":"R", "date_time_GMT":"2019-10-11701:00:002", "outcome":"home win REG", "game_id":2019020056, "away_team":"Bruins"}

{"home_goals":3, "season":20192020, "home_team":"Avalanche", "away_goals":2, "type":"R", "date_time_GMT":"2019-10-11701:00:002", "outcome":"home win REG", "game_id":2019020005, "away_team":"Bruins")

{"home_goals":3, "season":20192020, "home_team":"Bruins", "away_goals":0, "type":"R", "date_time_GMT":"2019-10-12723:00:002", "outcome":"home win REG", "game_id":2019020004, "away_team":"Devoins", "outcome":"home win REG", "game_id":201902004, "away_team":"Devoins", "outcome":"home win REG", "game_id":201902004, "away_team":"Devoins", "outcome":"home win REG", "game_id":201902004, "away_team:"Devoins", "outcome":"home win REG", "game_id":201902004, "outcome":"home win REG", "gam
```

Dotaz 2

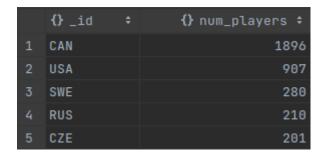
Získejte počet playoff zápasů jednotlivých týmů seřazených v sestupném pořadí v sezone 2019/2020.

```
match (g:GAME)
where g.season = 20192020 and g.type = "P"
with [g.home_team, g.away_team] as teams, g.game_id as game_id
unwind teams as team
return team, count(*) as appearances
order by appearances desc
```

"team"	"appearances"
"Stars"	24
"Islanders"	22
"Lightning"	22
"Canucks"	17
"Golden Knights"	17

Dotaz 3

Získejte hráče podle národnosti seřazené v sestupném pořadí.



```
match (p:PLAYER)
return p.nationality, count(*) as count_of_players
ORDER BY count_of_players DESC
LIMIT 5
```

"p.nationality"	 "count_of_players"
"CAN"	1896
"USA"	907
"SWE"	280
"RUS"	210
"CZE"	201

Dotaz 4

Získejte top 10 nejvyšších českých hráčů a vraťte jejich jména, výšku, datum narození, primární pozici.

Neo4i

```
match (p:PLAYER)
where p.nationality = "CZE"

return p.firstName, p.lastName, p.height_cm, p.birthDate,
p.primaryPosition

ORDER BY p.height_cm DESC

LIMIT 10
```

"p.firstName"	"p.lastName"	"p.height_cm"	"p.birthDate"	"p.primaryPosition"
"Andrej"	"Sustr"	200.66	"1990-11-29 00:00:00"	"D"
"Marek"	"Malik"	198.12	"1975-06-24 01:00:00"	"D"
"Martin"	"Hanzal"	198.12	"1987-02-20 00:00:00"	"C"
"David"	"Koci"	198.12	"1981-05-12 01:00:00"	"LW"
"Michal"	"Sykora"	195.58	"1973-07-05 01:00:00"	"D"

Dotaz 5

Získání počtu gólů vstřelených hráči v základní sezóně 2019/2020 seřazených v sestupném pořadí.

```
db.game.aggregate([
                     {$match: {season: 20192020, type: "R"} },
                    {\$project: {all_players: {\$setUnion:
["$home players", "$away players"]}}},
                    {$unwind: "$all_players"},
                    {$group: { id: "$all players.player id",
num goals: {$sum: "$all players.goals"}}},
                    {$lookup: {
                             from: "player",
                             localField: "_id",
                             foreignField: "player id",
                             as: "player info"
                    } } ,
                        $replaceRoot: { newRoot: { $mergeObjects: [
{ $arrayElemAt: [ "$player info", 0 ] }, "$$ROOT" ] }
                    },
                    { $project: {
                             firstName : 1,
                             lastName: 1,
```

```
        () _id : () firstName
        : () lastName
        : () nationality
        : () num_goals :

        1
        8477956 David
        Pastrnak
        CZE
        48

        2
        8471214 Alex
        Dvechkin
        RUS
        48

        3
        8479318 Auston
        Matthews
        USA
        47

        4
        8477934 Leon
        Draisaitl
        DEU
        43

        5
        8476459 Mika
        Zibanejad
        SWE
        41
```

Neo4i

```
match (g:GAME)
where g.season = 20192020 and g.type = "R"
match (p:PLAYER)-[pl:PLAYS]->(g:GAME)
return p.firstName, p.lastName, p.player_id, p.nationality,
sum(pl.goals) as goals
order by goals desc
```

"p.firstName"	 "p.lastName"	 "p.player_id" -	 "p.nationality"	"goals"
"Alex"	"Ovechkin"	8471214	"RUS"	48
"David"	"Pastrnak"	8477956	CZE"	48
"Auston"	"Matthews"	8479318	"USA"	47
"Leon"	 "Draisaitl"	8477934	"DEU"	43
"Mika"	 "Zibanejad"	 8476459	"SWE"	41

Dotaz 6

Získejte góly, asistence, body, odehrané zápasy a body na zápas hráčů v základní části sezóny 2019/2020 seřazené podle bodů v sestupném pořadí.

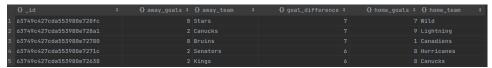
```
as: "player info"
                    } } ,
                         $replaceRoot: { newRoot: { $mergeObjects: [
{ $arrayElemAt: [ "$player info", 0 ] }, "$$ROOT" ] }
                     { $project: {
                             firstName : 1,
                             lastName: 1,
                             nationality: 1,
                             games played: 1,
                             num goals: 1,
                             num assists: 1,
                             num_points: {$add: ["$num_goals",
"$num assists"]},
                             points per game: {$divide: [{$add:
["$num_goals", "$num_assists"]}, "$games_played"]}
                     } } ,
                     {$sort: {num_points: -1}}
Neo4i
match (g:GAME)
where g.season = 20192020 and g.type = "R"
match (p:PLAYER) - [pl:PLAYS] -> (g:GAME)
return p.firstName,
     p.lastName,
     p.player id,
     p.nationality,
     sum(pl.goals) as goals,
     sum(pl.assists) as assists,
     sum(pl.goals + pl.assists) as points,
     count(*) as occurences,
     toFloat(sum(pl.goals + pl.assists)) / count(*) as
points per game
order by points desc
```

"p.firstName"	"p.lastName"	 "p.player_id"	"p.nationality"	goals"	"assists"	"points"	"occurences"	"points_per_game"
"Leon"	"Draisaitl"	8477934	"DEU"	43	67	110	71	1.5492957746478873
"Connor"	"McDavid"	8478402	"CAN"	34	63	97	64	1.515625
"Nathan"	 "MacKinnon" 	 8477492	"CAN"	36	60	96	72	1.3333333333333333
"Artemi"	 "Panarin"	8478550	"RUS"	32	63	95	69	1.3768115942028984
"David"	 "Pastrnak" 	 8477956	"CZE"	48	47	95	73	1.3013698630136987

Dotaz 7

Top 5 nejvyšší gólový rozdíl v jednom zápase mezi dvěma týmy v sezóně 2019/2020.

MongoDB



Neo4j

```
match (g:GAME)
```

return g.home_team, g.away_team, abs(g.home_goals - g.away_goals) as
goal_diff, g.home_goals, g.away_goals

order by goal_diff desc

"g.home_team"	 "g.away_team"	 "goal_diff"	 "g.home_goals"	 "g.away_goals"
"Canadiens"	 "Bruins" 	7	1	8
"Lightning"	"Canucks"	 7	9	2
"Wild"	"Stars"	7	7	0
"Canucks"	"Kings"	6	8	2
"Penguins"	 "Flyers" 	6	 7 -	1

Dotaz 8

Týmy, proti kterým dal gól hráč "Alex Ovechkin" a počet těchto golů.

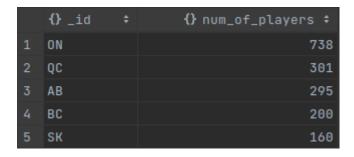
```
db.game.aggregate([
         {$match: {season: 20192020, type: "R"} },
         {\$unwind: "\$away players"},
         {$lookup: {
             from: "player",
             localField: "away players.player id",
             foreignField: "player id",
             as: "player info"
         } } ,
         {$replaceRoot: { newRoot: { $mergeObjects: [ { $arrayElemAt:
[ "$player info", 0 ] }, "$$ROOT" ] } }},
         {$match: {lastName: "Ovechkin", firstName: "Alex"}},
         {$group: {
             id: "$home team",
             goals recieved home: {$sum: "$away players.goals"}
         { $merge : { into : "Ovechkin scored" } }
]);
db.game.aggregate([
         {$match: {season: 20192020, type: "R"} },
         {\$unwind: "\$home players"},
         {$lookup: {
             from: "player",
             localField: "home players.player id",
             foreignField: "player id",
             as: "player info"
         } } ,
         {$replaceRoot: { newRoot: { $mergeObjects: [ { $arrayElemAt:
[ "$player info", 0 ] }, "$$ROOT" ] } }},
         {\( \frac{1}{2}\) match: \( \lambda \) astName: \( \lambda \) vechkin'', \( \frac{1}{2}\) firstName: \( \lambda \) Alex'' \\ \} \),
         {$group: {
             id: "$away team",
            goals recieved away: {$sum: "$home players.goals"}
         {$sort: {goals recieved: -1}},
         { $merge : { into : "Ovechkin scored" } }
]);
db.Ovechkin scored.aggregate([
         {$project: {
            goals_recieved: {$add: ["$goals recieved home",
"$goals recieved away"]}
        } } ,
         {$sort: {goals recieved: -1}}
]);
```

```
match (g:GAME)
where g.type = "R" and g.season = 20192020
match (p:PLAYER)-[pl:PLAYS]->(g:GAME)
where p.lastName = "Ovechkin" and p.firstName = "Alex"
return CASE
WHEN pl.team = g.away_team THEN g.home_team
ELSE g.away_team
END as opposing_team, sum(pl.goals) as Ovechkins_goals
order by Ovechkins goals desc
```

"opposing_team"	 "Ovechkins_goals"
"Devils"	5
"Senators"	 4
"Islanders"	3
"Hurricanes"	3
"Predators"	3

Dotaz 9

Získejte všechny kanadské provincie a jejich počty hráčů, kteří hráli v jakékoli sezóně.



```
match (p:PLAYER)
where p.nationality = "CAN"
return p.birthStateProvince, count(*) as players
order by players desc
```

"p.birthStateProvince"	 "players"
"ON"	738
"QC"	 301
"AB"	 295
"BC"	200
"SK"	160

Dotaz 10

Získejte týmy s nejvíce vítězstvími v základní hrací době v sezóně 2019/2020 (základní část + playoff) seřazené v sestupném pořadí.

```
{$group: {
                    id: "$away team",
                    away wins: {$sum:
                             {$cond: [ { $lt: [ "$home goals",
"$away goals" ] },
                                 1,
                                  0]}},
                } } ,
                { $merge : { into : "team away wins" } }
]);
db.team home wins.aggregate([
                { $100kup: {
                    from: "team_away_wins",
                    localField: " id",
                    foreignField: " id",
                    as: "wins"
                {$replaceRoot: { newRoot: { $mergeObjects: [ {
$arrayElemAt: [ "$wins", 0 ] }, "$$ROOT" ] } }},
                {$project: {
                    _id: 1,
                    wins: {$add: ["$away wins", "$home wins"]}
                {$sort: {wins: -1}}
]);
```

```
Neo4j
match (g:GAME)
where g.season = 20192020
with [{team: g.home_team, win: case when g.home_goals > g.away_goals
then 1 else 0 end},
{team: g.away_team, win: case when g.away_goals > g.home_goals then
1 else 0 end}] as teams, g.game_id as game_id
unwind teams as team
return team.team as team, sum(team.win) as wins
order by wins desc
```

"team"	"wins"
"Lightning"	61
"Stars"	 52
"Golden Knights"	 51
"Avalanche"	51
"Flyers"	51

Závěr

V této semestrální páci jsem si vybral databázi NHL, která byla poměrně velká, takže vytváření create scriptu pro jednotlivé databáze bylo časově náročné. Nahrávání dat do MongoDB bylo velmi ryhchlé oproti Neo4j, kde pro jisté vztahy nahrávání trvalo řádově déle. Na druhou stranu, MongoDB bylo mnohem méně přímočaré v dotazování a dotazy byly komplikovanější i více časově náročné. Neo4j v tomto ohledu výrazně předčilo MongoDB.

Při dokončování práce jsem se přesvědčil, že některé části mých databází mohli být navrženy lépe. Zejména rozdělení na tým domácích a hostů bylo problematické v dotazování v MongoDB.